



IA901-Projeto Final

**Segmentação de Tumores Cerebrais em Ressonâncias Magnéticas Multimodais
usando ACU-Net 2.5D**

Alunos:

Oscar Eduardo Ortega Rodriguez	RA 207726
Natália da Silva Guimarães	RA 298997

Sumário

Abstrato.....	3
Brain Tumor Segmentation Database (BraTS).....	4
Modalidades.....	4
Formato.....	6
Pré-processamento.....	7
N4 Bias Field Correction (Opcional).....	7
Normalização de intensidade (Brain-Only Z-Score).....	8
Desconstrução Lógica do Ground Truth (Máscara).....	9
Otimização Espacial e Data Augmentation.....	10
Comparativa Metodológica: 2D Tradicional vs. Proposta 2.5D.....	11
Implementação.....	11
Auditoria Visual e Inspeção dos Tensores.....	12
Arquitetura do Modelo.....	14
ACU-Net (Attention-based Convolutional U-Net).....	14
Caminho de Contração (Encoder) e Extração de Características.....	14
Mecanismo de Portões de Atenção (Attention Gates).....	14
Caminho de Expansão (Decoder) e Reconstrução Espacial.....	15
Resultados.....	16
Convergência da Função de Perda (Dice Loss).....	16
Avaliação Qualitativa: Inferência em Conjunto Cego (Holdout).....	17
Análise Quantitativa e Matriz de Confusão Píxel a Píxel.....	20
Referencias.....	23

Abstrato

- **Objetivos:** Implementar e validar a arquitetura ACU-Net para segmentação automatizada de gliomas em RM, focando na precisão de sub-regiões (Tumor Inteiro, Núcleo e Realçado) utilizando a base de dados BraTS.
- **Métodos:** O pipeline integra o dataset multimodal (T1, T1Gd, T2, FLAIR) com pré-processamento rigoroso, utilizando uma abordagem 2.5D com Attention Gates para refinar a extração de características.
- **Resultados:** O modelo demonstrou alta capacidade de generalização e fidelidade na captura de morfologias complexas, atingindo uma acurácia média de 85,64% (Dice Score) e convergência estável com Dice Loss de 0,1436.
- **Conclusão:** A abordagem proposta provou ser uma ferramenta robusta para o suporte clínico, superando o desbalanceamento inerente aos dados e estabelecendo um método eficiente para o delineamento tumoral no planejamento terapêutico com chances de melhoria na detecção da classe mais desafiadora.

Brain Tumor Segmentation Database (BraTS)

Modalidades

Imagens multimodais são uma abordagem que visa integrar informações provenientes de diferentes modalidades. Estudos de imagem multimodal na doença de Parkinson demonstraram que combinações de diferentes métodos, sensíveis a características teciduais complementares, podem ser úteis para o diagnóstico diferencial de distúrbios parkinsonianos, proporcionando uma distinção mais precisa do que as técnicas isoladas.[4]

Todas os scans multimodais do BraTS estão disponíveis como arquivos NIfTI (.nii.gz) e descrevem a) nativo (**T1**) e b) post-contrast T1-weighted (**T1Gd**), c) T2-weighted (**T2**), and d) T2 Fluid Attenuated Inversion Recovery (**FLAIR**) volumes. [5] Para entender melhor essas modalidades estruturais em 3D, eles são descritos a seguir:

- a) **T1 ou T1-weighted (T1 nativa)**: ressonância magnética estrutural sem contraste. Oferece uma excelente delimitação anatômica geral do cérebro saudável, servindo como mapa de referência básico.
- b) **T1Gd ou T1c (T1-weighted contrast-enhanced)**: ressonância magnética T1 depois da administração de um agente de contraste baseado em Gadolínio. É utilizado principalmente para identificar as áreas hipertensas onde a barreira hematoencefálica está rompida, delimitando o tumor ativo ou realçado.
- c) **T2 ou T2-weighted**: ressonância magnética ponderada em T2. Nessa modalidade, a água e os fluidos corporais aparecem mais brilhantes (hipertensos), o que ajuda fortemente a visibilizar e estudar a massa geral do tumor.
- d) **FLAIR (Fluid Attenuated Inversion Recovery ou T2-FLAIR)**: uma técnica baseada em T2 onde é suprimido o sinal líquido cefalorraquídeo livre (o qual passa a se ver de uma forma obscura). Isto permite ressaltar de forma clara o líquido preso nos tecidos corporais, facilitando a detecção do edema peritumoral (a inchação ao redor do tumor).




Figura 1: Exemplo de scan de paciente no dataset BraTS

Nos arquivos de segmentação (_seg.nii.gz) do conjunto de dados BraTS 2018, os especialistas médicos anotaram o volume pixel a pixel (ou voxel a voxel), atribuindo números específicos a cada região do tumor. O número 3 não é utilizado por motivos históricos de consistência com edições anteriores do desafio. Cada uma destas numerações corresponde a uma sub-região patológica altamente específica do glioma, conforme detalhado abaixo [6]:

- **Classe 1: Núcleo necrótico e sem realce (NCR/NET):** Refere-se às células tumorais mortas (necrose) ou frações do núcleo tumoral que não retêm o agente de contraste. Visualmente, manifesta-se com hipointensidade (escuro) em T1CE e, habitualmente, com hiperintensidade (brilhante) em T2. [6]
- **Classe 2: Edema peritumoral (ED):** Compreende o tecido cerebral inflamado e edematoso que circunda a massa principal. Embora não seja uma massa sólida, abriga células tumorais infiltradas. É caracterizado por um sinal fortemente brilhante e nítido na sequência FLAIR. [6]
- **Classe 4: Tumor realçado ou ativo (ET):** Identifica a porção mais agressiva e densa do câncer, apresentando crescimento acelerado e ruptura da barreira hematoencefálica. Apresenta-se como uma massa ou anel intensamente brilhante na modalidade T1CE. [6]

A técnica de cada uma dessas modalidades permite a captura de diferentes regiões de tumor, incluindo o tumor com realce (**Enhancing Tumor-ET**), núcleo do tumor (**Tumor Core-TC**) e tumor inteiro (**Whole Tumor-WT**), indicando as 3 classes de segmentação do nosso problema. Para melhor entendimento de cada uma delas, segue a descrição:

- **Enhancing Tumor (ET) / Tumor com Realce:** Representa a parte ativa e mais maligna do tumor. É definida com precisão pelas áreas que apresentam captação hiperintensa de sinal exclusivamente na sequência T1CE, devido à ruptura da barreira hematoencefálica.[6]
- **Tumor Core (TC) / Núcleo do Tumor:** Corresponde à massa sólida central do tumor primário. Inclui o tumor com realce (ET) e as partes necróticas ou sem realce. O TC é delineado avaliando os exames T1, T1CE e T2 para contornar a massa sólida, excluindo explicitamente o inchaço circundante. [6]
- **Whole Tumor (WT) / Tumor Inteiro:** Captura a extensão fisiológica completa da doença. Engloba todo o Tumor Core (TC) mais o tecido edematoso peritumoral (o inchaço ou tecido invadido ao redor da massa sólida). O WT é mais facilmente detectável através da sequência FLAIR, onde a região inchada permanece brilhante. [6]

Relação das regiões com as Classes de Segmentação (1, 2 e 4):

- **Whole Tumor (WT / Tumor Inteiro):** É a união das classes 1 + 2 + 4. Representa absolutamente tudo o que está afetado pela doença.[3]
- **Tumor Core (TC / Núcleo do Tumor):** É a união das classes 1 + 4. Representa a massa tumoral sólida, removendo o edema/inflamação.[3]
- **Enhancing Tumor (ET / Tumor com Realce):** É unicamente a classe 4, que corresponde à zona mais ativa.[3]

Formato

É crucial diferenciar a representação da intensidade de imagens médicas volumétricas (voxels) das imagens digitais convencionais (pixels). Enquanto um pixel padrão utiliza 8 bits por canal, limitando a intensidade máxima a 255, a intensidade de um voxel de RM é um valor inteiro diretamente proporcional aos sinais de radiofrequência emitidos pelos átomos de hidrogênio no corpo. Esses dados de intensidade são tipicamente armazenados em formatos float de 16 ou 32 bits, cuja precisão varia de acordo com o equipamento de ressonância magnética (MRI), as configurações do campo magnético e as características do paciente.

No que diz respeito à estrutura de dados do BraTS, cada paciente está associado a cinco arquivos NIfTI (.nii): quatro correspondem às modalidades de imagem (T1, T1Gd, T2, FLAIR) e o quinto, denominado '_seg.nii', contém os rótulos (labels) de segmentação (0, 1, 2, 4). Uma análise do shape desses arquivos revela a dimensão (240, 240, 155), onde

- **240 x 240** representa a resolução da fatia 2D
- **155** indica o número de fatias horizontais, correspondendo à profundidade do volume cerebral 3D.

A seguir segue uma amostra dos dados de um dos pacientes do BraTS 2018:

```
=== Analisando BraTS 2018: Brats18_ICIA03_338_1 ===

Modalidade: T1
- Shape (H, W, D): (240, 240, 155)
- Intensidade Mínima: 0.0
- Intensidade Máxima: 823.0
- Média de Intensidade: 35.6
- Desvio Padrão de Intensidade: 82.7
-----

Modalidade: T1CE
- Shape (H, W, D): (240, 240, 155)
- Intensidade Mínima: 0.0
- Intensidade Máxima: 290.0
- Média de Intensidade: 10.9
- Desvio Padrão de Intensidade: 26.0
-----

Modalidade: T2
- Shape (H, W, D): (240, 240, 155)
- Intensidade Mínima: 0.0
- Intensidade Máxima: 763.0
- Média de Intensidade: 42.4
- Desvio Padrão de Intensidade: 112.5
-----

Modalidade: FLAIR
- Shape (H, W, D): (240, 240, 155)
- Intensidade Mínima: 0.0
- Intensidade Máxima: 449.0
- Média de Intensidade: 18.1
- Desvio Padrão de Intensidade: 44.4
-----

Modalidade: SEG
- Shape (H, W, D): (240, 240, 155)
- Intensidade Mínima: 0.0
- Intensidade Máxima: 4.0
- Média de Intensidade: 0.0
- Desvio Padrão de Intensidade: 0.1
- Labels únicos: [0. 1. 2. 4.]
-----

=====
```

Figura 2: Exemplo de dimensões de paciente no dataset BraTS

Pré-processamento

Imagens brutas provenientes de diferentes centros hospitalares e scanners sofrem com variabilidades físicas intrínsecas que comprometem a capacidade de generalização das redes convolucionais. Para mitigar esses artefatos, o pipeline adota as seguintes camadas consecutivas de tratamento. [9]

Vale ressaltar que as imagens do *dataset* já passaram por skull-stripping (remoção digital do crânio para focar apenas no tecido cerebral), foram co-registradas (alinhadas) para o mesmo template anatômico (SRI24) e amostradas para uma resolução isotrópica e uniforme de 1mm^3 (resultando no volume explicado anteriormente de $240 \times 240 \times 155$ voxels). [1]

N4 Bias Field Correction (Opcional)

O campo magnético gerado pelas bobinas das máquinas de ressonância magnética (sejam de 1.5T ou 3T) não é perfeitamente uniforme. Isso induz um artefato suave de baixa frequência conhecido como *bias field*, que faz com que pixels do mesmo tecido biológico apresentem intensidades de cinza diferentes dependendo da sua posição espacial no scanner. A correção N4 modela esse viés de forma multiplicativa no domínio espacial e aplica um filtro inverso para homogeneizar o brilho dos tecidos. [2]

No entanto, os próprios organizadores do BraTS alertam que a aplicação global de correções de viés pode obliterar (destruir) o sinal da sequência **T2-FLAIR**, que é indispensável para detectar a região de edema. Portanto, restringir essa correção às modalidades **T1** e **T1CE** garante a uniformidade sem apagar as características críticas da doença. [2]




Figura 3: Comparativo visual do corte axial de uma RM (modalidade T1/FLAIR) evidenciando o efeito do algoritmo N4 Bias Field Correction via SimpleITK.




Figura 4: Comparativo visual do corte axial de uma RM via histograma.

No gráfico sobreposto, a distribuição original costuma ser mais "espalhada" ou apresentar múltiplos picos anormais devido à iluminação desigual. A correção N4 tende a condensar os valores de tecidos semelhantes num mesmo intervalo de intensidade, criando picos mais finos e definidos, o que facilita enormemente o trabalho da rede neural ao interpretar os tons de cinza.

Normalização de intensidade (Brain-Only Z-Score)

A normalização por escore padronizado (Z-Score) reposiciona os dados para uma distribuição com média 0 e desvio padrão 1. Contudo, calcular o Z-Score sobre a imagem inteira incluiria o imenso fundo preto (ar) que envolve a cabeça, distorcendo gravemente a estatística. A técnica *Brain-Only* extrai a média μ e o desvio padrão σ **apenas** dos voxels pertencentes à massa encefálica, aplicando a equação de padronização unicamente nesta região de interesse:

$$X_{norm} = X - \mu_{cerebro} / \sigma_{cerebro}$$

Isto permite padronizar a distribuição de dados para que a rede neural não precise reaprender escalas de brilho para cada paciente. Ignorar o fundo impede que o excesso de pixels pretos distorça a média estatística para perto de zero.




Figura 5: Normalização de dados após aplicação do filtro Brain-Only Z-Score

Desconstrução Lógica do Ground Truth (Máscara)

O BraTS entrega uma máscara unificada onde diferentes valores inteiros representam diferentes partes do tumor. Se passássemos isso direto para a rede, ela tentaria criar uma relação matemática falsa (achando que a classe 4 é matematicamente maior/mais importante que a classe 1). A ideia é resolver isso aplicando portas lógicas. Fazendo uma varredura da matriz procurando padrões específicos para construir três alvos binários isolados:

- WT (Whole Tumor): Tudo o que é doença (Rótulos 1, 2 ou 4).
- TC (Tumor Core): A massa sólida excluindo o edema (Rótulos 1 ou 4).
- ET (Enhancing Tumor): Apenas a margem ativa (Rótulo 4).



Figura 6: Representação colorida dos rótulos discretos originais fornecidos pelo dataset BraTS (Edema, Núcleo não-realçado e Tumor realçado)

Com as imagens normalizadas e a máscara desmembrada, este passo simula o exato momento em que os tensores são injetados na rede neural. Utilizamos o np.stack para colar as quatro matrizes 3D umas contra as outras. O resultado é um único super-tensor geométrico onde o último eixo guarda a "cor" (ou modalidade) do voxel.

- Formato do Input (X): (240, 240, 155, 4) -> (Altura, Largura, Fatias, 4 Modalidades)
- Formato da Label (Y): (240, 240, 155, 3) -> (Altura, Largura, Fatias, 3 Classes Alvo)




Figura 7: Esquema lógico de conversão dos rótulos brutos (Labels 1, 2 e 4) para as três sub-regiões de relevância clínica e avaliação computacional (Whole Tumor, Tumor Core e Enhancing Tumor)

Otimização Espacial e Data Augmentation

Para evitar o overfitting (memorização dos pacientes) e acelerar o treinamento, implementamos duas técnicas dinâmicas:

- **Augmentation On-the-Fly:** Aplicamos transformações estocásticas (espelhamento com 50% de probabilidade e injeção de ruído Gaussiano) durante a geração dos lotes. Isso força o modelo a generalizar a biologia do tumor.
- **Recorte Anatômico (Cropping):** Reduzimos a imagem de 240×240 para 160×192, eliminando o fundo preto excessivo (ar) em torno do crânio. Isso poupa memória.




Figura 8: O mesmo recorte geométrico aplicado à máscara de anotação médica (Ground Truth)




Figura 9: Comparativo entre a fatia axial original 240 x 240 da modalidade FLAIR e a sua versão otimizada (160 x 192)

Comparativa Metodológica: 2D Tradicional vs. Proposta 2.5D

A metodologia descrita no artigo base fundamenta-se em uma estratégia estritamente 2D. Nela, o volume tridimensional é seccionado em fatias individuais, redimensionadas para 128×128 , que alimentam a rede neural de forma isolada.[6]

- **Limitação do 2D:** Ao processar apenas a fatia z , o modelo ignora a natureza volumétrica do tumor, perdendo a continuidade espacial entre as fatias adjacentes ($z - 1$ e $z + 1$) e, conseqüentemente, o contexto de profundidade.
- **Obstáculo do 3D:** Convoluções volumétricas diretas ($240 \times 240 \times 155$) demandam recursos computacionais extremos e uma capacidade de VRAM que muitas vezes excede o hardware disponível.

A Solução 2.5D: Nossa abordagem mantém a eficiência da arquitetura U-Net 2D, mas integra o contexto espacial ao empilhar fatias vizinhas como canais de entrada. Ao fornecer simultaneamente as fatias $z - 1$, z e $z + 1$, permitimos que o modelo realize a predição da fatia central com embasamento volumétrico.

Implementação

Esta técnica é amplamente adotada em soluções de alto desempenho em competições de segmentação médica, como o BraTS. A adaptação principal reside no *DataLoader*: em vez de tensores com 4 canais, utilizaremos tensores de 12 canais (decorrentes da combinação de 3 fatias para cada uma das 4 modalidades).

O ajuste na primeira camada convolucional para suportar esses 12 canais será feito sem comprometer o rigoroso controle de qualidade estatística já estabelecido em nosso código.

Auditoria Visual e Inspeção dos Tensores

Visando assegurar o rigor técnico no fluxo de processamento dinâmico, estabeleceu-se uma etapa de auditoria visual e inspeção dos tensores (*Sanity Check*). Este procedimento opera como uma validação terminal, capturando e analisando a integridade matemática de um lote (*batch*) proveniente da estratégia 2.5D no instante imediatamente anterior à injeção dos dados nas camadas convolucionais da arquitetura ACU-Net. As seguintes **figuras** ilustram o resultado dessa inspeção, evidenciando a fidelidade das modalidades de RM e a conformidade geométrica das máscaras.




Figura 11: Auditoria Visual antes da injeção de dados




Figura 12: Auditoria Visual antes da injeção de dados




Figura 13: Auditoria Visual antes da injeção de dados

Validação da Normalização (Segmento Superior):

A inspeção das fatias centrais para as sequências T1, T1CE e FLAIR ratifica a aplicação do filtro *Brain-Only Z-Score*. A convergência da média μ para valores decimais em todos os canais confirma o centramento dos dados na origem. Essa calibração estatística é vital para que as funções de ativação operem em regime de estabilidade desde as épocas iniciais, mitigando riscos de saturação ou congelamento de gradientes.

Paralelamente, a estabilização do desvio padrão σ em patamares inferiores à unidade teórica 0.4 e 0.7 atesta a eficácia da máscara cerebral. Ao forçar o fundo extracraniano ao zero absoluto, a variância global é ancorada, permitindo que a rede neural ignore o ruído inerte e foque exclusivamente no contraste relativo do parênquima e das estruturas tumorais.

Integridade do Mapeamento Clínico (Segmento Inferior):

O painel inferior valida a desconstrução lógica aplicada ao *Ground Truth*. O volume unificado de anotação médica, originalmente composto por rótulos discretos (1, 2 e 4), foi decomposto em três tensores binários independentes para a avaliação computacional:

- **Canal 0 (Whole Tumor):** Abrange a extensão completa da massa patológica.
- **Canal 1 (Tumor Core):** Delineia a massa sólida, excluindo o edema.
- **Canal 2 (Enhancing Tumor):** Isola especificamente as zonas de realce ativo.

Arquitetura do Modelo

ACU-Net (Attention-based Convolutional U-Net)

A segmentação automatizada de gliomas em exames de ressonância magnética exige uma topologia que consiga mapear simultaneamente o contexto global do órgão e os detalhes estruturais das fronteiras tumorais, isto é um problema de classificação píxel a píxel severamente desbalanceado, já que há muito mais cérebro saudável do que tumor. [1] Para cumprir este requisito, o modelo implementado baseia-se na arquitetura **ACU-Net**, uma evolução da clássica rede U-Net que incorpora mecanismos de atenção agnóstica, operando de forma simétrica entre caminhos de contração e expansão. [6]

Caminho de Contração (Encoder) e Extração de Características

A etapa de *Encoder* opera como uma sucessão de camadas voltadas à subamostragem e ao mapeamento gradual de atributos semânticos. A unidade elementar desse percurso é o bloco **DoubleConv**, constituído por um par de convolução bidimensional com kernels de 3x3 e preenchimento (*padding*) unitário, estratégia que assegura a integridade das proporções espaciais ao longo do processamento.

Posteriormente a cada convolução, aplica-se uma camada de Normalização em Lote (*Batch Normalization*) — elemento vital para a estabilidade da convergência e mitigação do desvanecimento do gradiente — complementada pela função de ativação ReLU (*Rectified Linear Unit*).

A redução da dimensionalidade entre os patamares de resolução é executada por operações de *MaxPool* com janelas de 2x2 e passo (*stride*) de 2, o que segmenta a resolução planar pela metade em cada nível. A trajetória de compressão (*Encoder*) da rede ACU-Net processa os dados volumétricos 2.5D por intermédio de sucessivos blocos **DoubleConv** baseados na arquitetura de Talukder et al. (2025). Para esta implementação, a capacidade da rede foi expandida, iniciando o mapeamento com 64 filtros de atributos. A cada estágio de *Max Pooling*, a resolução da imagem é reduzida pela metade enquanto a densidade de canais sofre uma progressão aritmética dobrada (64 -> 128 -> 256 -> 512), finalizando na estrutura de *bottleneck* que comporta uma profundidade de **1024 filtros**, assegurando a codificação de informações semânticas de elevada abstração.

Mecanismo de Portões de Atenção (Attention Gates)

A principal inovação desta arquitetura reside na sofisticação das **skip connections**. Diferente da U-Net convencional, onde os mapas de atributos de alta fidelidade extraídos pelo **Encoder** são meramente replicados e concatenados ao **Decoder**, este método tradicional acarreta uma redundância excessiva de dados provenientes do parênquima saudável. Tal configuração exige que o modelo despense recursos computacionais desnecessários para filtrar o ruído de fundo e focar na patologia.

A ACU-Net soluciona este entrave ao introduzir Portões de Atenção (*Attention Gates* - AGs) no fluxo dessas conexões. O AG opera como um mecanismo de filtragem seletiva, integrando dois fluxos de informação complementares:

- O vetor de atributos locais, oriundo do *Encoder*, que preserva detalhes anatômicos e espaciais de alta resolução.
- O sinal de ativação global, proveniente dos níveis profundos do *Decoder*, responsável pelo contexto semântico abstrato necessário para a identificação da massa tumoral.

No funcionamento interno do **Attention Gate**, tanto os atributos locais x quanto o sinal de ativação global g sofrem uma projeção para um domínio latente comum através de convoluções de kernel 1x1. A integração desses tensores ocorre por meio de uma soma aditiva submetida à não-linearidade da função **ReLU** (*Rectified Linear Unit*), preterindo o uso de tangentes. A sequência de processamento finaliza com uma nova operação convolucional 1x1 e uma normalização via função **Sigmóide** σ , produzindo os coeficientes de atenção α . Esse mapa resultante modula a intensidade das características entre 0 e 1, permitindo que a rede suprima ativamente o ruído proveniente de tecidos saudáveis. [6]

Caminho de Expansão (Decoder) e Reconstrução Espacial

A etapa de *Decoder* executa a amostragem ascendente (*upsampling*) por meio de convoluções transpostas (*ConvTranspose2d*) com filtros 2x2 e passo de 2. Este processo restaura a geometria planar de forma rigorosamente simétrica ao caminho de contração, restabelecendo as dimensões originais da imagem de entrada.

Posteriormente a cada expansão, o tensor resultante é concatenado ao eixo de canais com o mapa de atributos análogo do *Encoder*, o qual foi previamente processado pelo Portão de Atenção para a remoção de redundâncias. Essa integração assegura que o fluxo de subida receba, simultaneamente, a alta fidelidade na localização de bordas e o contexto semântico abstrato. O volume combinado é então submetido a um bloco *DoubleConv* para a regularização de possíveis artefatos de interpolação.

O estágio terminal do *Decoder* utiliza uma operação convolucional de kernel 1x1, responsável por comprimir o volume de 64 filtros em uma estrutura de saída com 3 canais, representando as sub-regiões tumorais (Whole Tumor, Tumor Core e Enhancing Tumor). Com o intuito de preservar o equilíbrio estatístico e a robustez do aprendizado, a arquitetura prescinde do uso da função Sigmóide na camada final. A rede emite variáveis logísticas brutas (*logits*), delegando a normalização probabilística para o escopo interno da função de perda (*Dice Loss*), o que previne flutuações críticas no fluxo de gradientes.

Resultados

A análise de modelos de Deep Learning voltados à segmentação médica demanda uma perspectiva integrada, relacionando a estabilidade da convergência durante o treinamento com a capacidade de generalização morfológica em dados inéditos. Os experimentos realizados validam a eficácia da arquitetura ACU-Net sob a abordagem 2.5D na delimitação de gliomas, superando o severo desbalanceamento de classes característico das imagens de ressonância magnética.

Convergência da Função de Perda (Dice Loss)

O monitoramento da descida de gradiente ao longo de 100 épocas de treinamento comprova o aprendizado progressivo da rede. Em volumes médicos de alta complexidade, a amostragem por mini-lotes introduz uma variabilidade intrínseca, manifestada como oscilações de alta frequência na curva de erro bruto.

A seguinte figura apresenta esse comportamento: estabilizando-se em um patamar de *Dice Loss* próximo a 0.170. Esta estabilidade sugere a ausência de problemas com gradientes e indica que o Otimizador Adam, aliado aos *Attention Gates*, calibrou os pesos sinápticos de forma a minimizar as falsas classificações do tecido saudável.




Figura 14: Convergência da Função de Perda

O treinamento foi considerado os seguintes hiperparâmetros:

- Passos por épocas: 100
- Épocas: 100
- Learning Rate: 5e-5

Chegando em um resultado final de

Dice Loss: 0.1436 | Acerto (Dice Score): 85.64%

Avaliação Qualitativa: Inferência em Conjunto Cego (Holdout)

O potencial de generalização do modelo foi verificado qualitativamente por meio da inferência direta sobre um subconjunto de validação isolado, composto por pacientes não utilizados no treinamento. As seguintes figuras exibem um painel comparativo destacando as fatias de maior relevância clínica transversal de cinco casos distintos.

A comparação visual entre o *Ground Truth* (anotação dos especialistas) e a predição da rede demonstra uma captura de contornos de alta fidelidade. O modelo prova ser capaz de mapear morfologias complexas e irregulares, transcendendo formas geométricas genéricas.

As métricas de *Dice Score* para as 3 classes e os cortes específicos variaram entre eles, tendo uma porcentagem alta nas classes Whole Tumor e Tumor Core mas um desempenho mais baixo na classe de Enhancing Tumor. Isto reforça que a estratégia 2.5D oferece contexto espacial suficiente para delinear as fronteiras da neoplasia com rigor estrutural mas com margem de melhoria para futuros usos.




Figura 15: Avaliação Qualitativa das 3 classes estabelecidas (Amostra 1)

Segmentação IA Multiclasse - Brats18_CBICA_APR_1




Figura 16: Avaliação Qualitativa das 3 classes estabelecidas (Amostra 2)

Segmentação IA Multiclasse - BraTS20_Training_075




Figura 17: Avaliação Qualitativa das 3 classes estabelecidas (Amostra 3)

Segmentação IA Multiclasse - BraTS20_Training_025




Figura 18: Avaliação Qualitativa das 3 classes estabelecidas (Amostra 4)

Comparativo de Segmentação (Classe WT - Whole Tumor) - Paciente Inédito




Figura 19: Avaliação Qualitativa das 3 classes estabelecidas

Análise Quantitativa e Matriz de Confusão Píxel a Píxel

Para mensurar o impacto do desbalanceamento tecidual, realizou-se a extração de métricas através do achatamento dos tensores espaciais, resultando na Matriz de Confusão Píxel a Píxel. A matriz quantifica a discrepância entre o volume de Verdadeiros Negativos (fundo e cérebro saudável na ordem de milhões de voxels) e a classe de Verdadeiros Positivos (massa tumoral).

A resiliência da arquitetura frente a essa distorção estatística é evidenciada no gráfico de dispersão por paciente. O modelo alcançou uma acurácia média de 85.64% no conjunto de teste, validando a escolha do Coeficiente *Dice* em substituição ao erro quadrático tradicional. Esse desempenho posiciona o modelo desenvolvido em conformidade com os índices reportados pelo estado da arte para a segmentação do tumor completo (*Whole Tumor*).




Figura 20: Matriz de Confusão (Amostra 1)




Figura 21: Matriz de Confusão (Amostra 2)




Figura 22: Matriz de Confusão (Amostra 3)




Figura 23: Matriz de Confusão (Amostra 4)

Amostra	Classe	TP	FP	FN	TN	Dice Score (%)
1	Whole Tumor	1545	73	40	29062	96.47
	Tumor Core	1145	28	17	29530	98.07
	Enhancing Tumor	1031	90	22	29577	94.85
2	Whole Tumor	1279	150	29	29262	93.46
	Tumor Core	808	80	1	29831	95.23
	Enhancing Tumor	364	182	15	30159	78.70
3	Whole Tumor	1144	9	128	29439	94.35
	Tumor Core	331	0	793	29596	45.50
	Enhancing Tumor	242	2	520	29956	48.11
4	Whole Tumor	1987	205	31	28497	94.39
	Tumor Core	914	468	0	29338	79.62
	Enhancing Tumor	379	886	5	29450	45.97

Tabela 1: Dissecando a matemática das matrizes

1. O coeficiente de similaridade *Dice Score* é computado de maneira autônoma para cada componente da neoplasia, seguindo o formalismo matemático: $Dice = (2 * TP) / (2 * TP + FP + FN)$.
2. Observa-se que a categoria '*TN (Verdadeiros Negativos)*' apresenta magnitudes elevadas, uma vez que a volumetria predominante corresponde ao parênquima íntegro e ao espaço extracraniano.
3. Tal característica justifica a exclusão dos pixels classificados como fundo na métrica *Dice*. Caso a avaliação utilize a acurácia convencional, a rede neural atingiria índices superiores a 99% meramente pela predição das zonas escuras, o que ocultaria erros diagnósticos críticos e omissões na zona tumoral (Falsos Negativos). Apresentam-se adiante registros adicionais do ciclo de treinamento.

Conclusão

A implementação da arquitetura ACU-Net, aliada à abordagem 2.5D e ao uso de Portões de Atenção (Attention Gates), provou ser uma estratégia robusta para a segmentação automatizada de gliomas. A integração de um pipeline de pré-processamento permitiu que o modelo superasse as variabilidades estatísticas inerentes ao dataset BraTS, atingindo uma acurácia média (Dice Score) de 85,64%.

Embora o modelo tenha demonstrado alta fidelidade na delimitação das sub-regiões tumorais e na captura de morfologias complexas, a análise quantitativa revelou desafios pontuais na segmentação da classe de realce (Enhancing Tumor), sugerindo caminhos para futuras otimizações, como a exploração de perdas ponderadas (Weighted Loss) ou arquiteturas mais profundas. Em suma, este trabalho consolida um método eficiente de extração de características e segmentação semântica, reafirmando o potencial da inteligência artificial como suporte clínico essencial para o planejamento terapêutico e o delineamento preciso de tecidos oncológicos.

Referencias

- [1] B. H. Menze, A. Jakab, S. Bauer, J. Kalpathy-Cramer, K. Farahani, J. Kirby, et al. "The Multimodal Brain Tumor Image Segmentation Benchmark (BRATS)", IEEE Transactions on Medical Imaging 34(10), 1993-2024 (2015) DOI: 10.1109/TMI.2014.2377694
- [2] S. Bakas, H. Akbari, A. Sotiras, M. Bilello, M. Rozycki, J.S. Kirby, et al., "Advancing The Cancer Genome Atlas glioma MRI collections with expert segmentation labels and radiomic features", Nature Scientific Data, 4:170117 (2017) DOI: 10.1038/sdata.2017.117
- [3] S. Bakas, M. Reyes, A. Jakab, S. Bauer, M. Rempfler, A. Crimi, et al., "Identifying the Best Machine Learning Algorithms for Brain Tumor Segmentation, Progression Assessment, and Overall Survival Prediction in the BRATS Challenge", arXiv preprint arXiv:1811.02629 (2018)
- [4] G. Barbagallo et al. "Multimodal Imaging in Parkinson's Disease", International Review of Neurobiology (2016) DOI: 10.1016/bs.irm.2018.08.007; [5] K. Ito et al. "Imaging biomarkers in Parkinson's disease", (2017); [6] S. Zanigni et al. "Structural and functional MRI in Parkinsonism", (2017)
- [5] [MICCAI BraTS 2018: Data | Section for Biomedical Image Analysis \(SBIA\) | Perelman School of Medicine at the University of Pennsylvania](#)
- [6] Talukder, Alamin, Abu Layek, Aslam Hossain, Aminul Islam, Mohammad Nur-e-Alam, Mohsin Kazi et al. "ACU-Net: Attention-based convolutional U-Net model for segmenting brain tumors in fMRI images."
- [7] Produzido por meio de inteligência artificial. Tecnologia de IA Generativa, Google Gemini Pro
- [8] [NiBabel: Documentação para acesso e leitura de arquivos NIfTI](#)
- [9] N. J. Tustison, B. B. Avants, P. A. Cook, Y. Zheng, A. Egan, P. A. Yushkevich, and J. C. Gee, "N4ITK: improved N3 bias correction", IEEE Transactions on Medical Imaging 29(6), 1310-1320 (2010) DOI: 10.1109/TMI.2010.2046908
- [10] R. Beare, B. C. Lowekamp, Z. Yaniv, "Image Segmentation, Registration and Characterization in R with SimpleITK", J Stat Software, 86(8), DOI: 10.18637/jss.v086.i08, 2018.
- [11] Z. Yaniv, B. C. Lowekamp, H. J. Johnson, R. Beare, "SimpleITK Image-Analysis Notebooks: a Collaborative Environment for Education and Reproducible Research", J Digit Imaging., DOI: 10.1007/s10278-017-0037-8, 31(3): 290-303, 2018.
- [12] B. C. Lowekamp, D. T. Chen, L. Ibáñez, D. Blezek, "The Design of SimpleITK", Front. Neuroinform., 7:45. DOI: 10.3389/fninf.2013.00045, 2013.