



IA901-Projeto Final

Datasheets for datasets

Extração de Características em fMRI: Segmentação de Sub-regiões Tumorais via Convolutional U-Net em 3D

Alunos:

Oscar Eduardo Ortega Rodriguez	RA 207726
Natália da Silva Guimarães	RA 298997

Datasheet for Datasets: BraTS 2018/2020 (Adaptação para Projeto IA901)

1. Introdução (Introduction)

Para este projeto, utilizamos o conjunto de dados BraTS 2018, que é uma grande referência no estudo de tumores cerebrais. Ele reúne exames de Ressonância Magnética (RM) de 285 pacientes, organizados em quatro tipos de imagens essenciais: **T1**, **T1CE** (com contraste), **T2** e **FLAIR**. Com essas modalidades, conseguimos identificar partes específicas do tumor, como a área ativa, o núcleo e o inchaço ao redor. Antes de usar os dados, aplicamos uma limpeza para remover as partes do crânio (*skull-stripping*) e padronizamos a resolução das imagens para garantir que o modelo foque apenas no cérebro. Além disso, existe a versão BraTS 2020, que amplia esse banco para 368 volumes de RM, trazendo ainda mais diversidade clínica para validar modelos em situações reais.

No BraTS 2018, os pacientes são divididos entre os que possuem gliomas de alto grau (HGG, 210 pessoas) e baixo grau (LGG, 75 pessoas). Em nossa pesquisa, decidimos unir essas duas categorias em um único grupo para as etapas de treinamento, validação e teste, simplificando o processo de aprendizado da nossa rede neural sem separar os níveis de gravidade do tumor. [1]

1.1. Objetivos (Objectives)

O Brain Tumor Segmentation Database (BraTS), estabelecido por consórcios colaborativos da conferência MICCAI e da University of Pennsylvania, serve como um *benchmark* padronizado para a avaliação rigorosa de algoritmos de Deep Learning na segmentação de gliomas. O objetivo central do BraTS é a segmentação de tumores cerebrais intrinsecamente heterogêneos em imagens de Ressonância Magnética (RM) pré-operatórias multimodais, coletadas de diversas instituições. Especificamente, as edições BraTS 2018 e 2020 se concentram não apenas na segmentação, mas também na previsão da sobrevivência global dos pacientes. O BraTS 2020 expandiu seus objetivos ao incluir a avaliação da incerteza algorítmica nas segmentações de tumores (Tarefa 3), diferenciando-se da edição de 2018. [6]

2. Desenvolvimento (Development Process)

Entender de imagens médicas e neuro-oncologia não é nada fácil no começo. Como nossa equipe ainda não conhecia muito bem os detalhes físicos e estatísticos das ressonâncias magnéticas (fMRI), decidimos seguir um caminho mais prático e investigativo. Em vez de simplesmente aceitar os métodos prontos de engenharia de dados e modelagem, fomos construindo tudo aos poucos, refinando nosso trabalho a cada nova pergunta que surgia.

Para cada obstáculo que os dados nos traziam — como ruídos nas imagens ou a grande diferença entre os tipos de tumores — a gente procurava entender o problema a fundo. Esse esforço valeu a pena, porque conseguimos compreender a lógica matemática e clínica por trás de cada decisão técnica que tomamos, como o uso de filtros específicos ou a escolha das métricas de avaliação. No fim das contas, nosso sistema não é uma "caixa-preta"; é uma estrutura onde cada transformação pode ser explicada.

3. Perguntas e Workflow

- **Com qual propósito o dataset foi criado?** O Brain Tumor Segmentation Database (BraTS) foi estabelecido para prover um *benchmark* padronizado que viabilize a avaliação rigorosa de algoritmos de Deep Learning na segmentação de gliomas. A base visa superar os desafios críticos de delineamento de contornos e sub-regiões tumorais complexas. [1]
- **Quem criou o dataset?** O conjunto de dados é mantido por consórcios colaborativos vinculados à conferência MICCAI e à University of Pennsylvania, integrando dados multimodais de diversas instituições médicas globais. [1]
- **O que os dados representam?** Os dados compreendem exames de Ressonância Magnética (RM) multimodais tridimensionais (3D) de pacientes com diagnóstico de glioma.
- **Quais são as modalidades incluídas?** Cada volume do paciente integra quatro sequências estruturais fundamentais:
 - **T1 Nativa:** Oferece uma excelente delimitação anatômica do parênquima cerebral saudável.
 - **T1CE (T1-weighted contrast-enhanced):** Essencial para identificar áreas de ruptura da barreira hematoencefálica e o tumor ativo (realçado) após contraste.
 - **T2-weighted:** Foca na caracterização da massa tumoral sólida através do sinal hiperintenso de fluidos.
 - **FLAIR:** Suprime o sinal do líquido cefalorraquídeo para evidenciar o edema peritumoral e tecidos infiltrados.
- **Como é a estrutura técnica dos arquivos?** Os exames são distribuídos em formato NIfTI (.nii.gz), onde a intensidade dos *voxels* reflete sinais de radiofrequência em ponto flutuante. O volume possui *shape* de 240 x 240 x 155, representando a resolução axial e a profundidade volumétrica.
- **Existem rótulos (labels) associados?** Sim. Especialistas realizaram anotações manuais *voxel* a *voxel*: Classe 1 (NCR/NET), Classe 2 (Edema) e Classe 4 (Tumor Realçado).
- **Qual é o pensamento crítico por trás das escolhas de pré-processamento, como a normalização estrita do tecido cerebral, em vez de utilizar o Z-Score global nas imagens brutas?** Percebemos que, nas ressonâncias (fMRI), a maior parte do volume (cerca de 70% a 80%) é só "fundo preto" (espaço vazio). Se aplicássemos a normalização matemática comum em tudo, o tecido saudável do cérebro seria distorcido e teria valores estatísticos altíssimos. Para resolver isso, criamos a função `brain_only_zscore_normalize`, que calcula a distribuição estatística focando apenas nos *voxels* que realmente fazem parte do tecido orgânico (aqueles

com valor maior que zero). Assim, o valor 0 passa a representar exatamente a média do tecido, garantindo que a normalização seja justa para o cérebro.

- **Como funciona a desconstrução lógica da máscara original (Ground Truth) entregue pelo BraTS e por que essa etapa é importante?**

Questionamos se era correto usar os rótulos originais (1, 2 e 4) diretamente. Entendemos que as redes neurais poderiam interpretar esses números como uma ordem de valores (achando, por exemplo, que a classe 4 é "duas vezes mais importante" que a classe 2), o que não é verdade. Por isso, decidimos dividir a imagem em três canais separados e binários: Whole Tumor, Tumor Core, Enhancing Tumor. Essa solução reflete a forma como a doença se manifesta biologicamente e evita que o modelo aprenda com um erro matemático.

- **É viável usar e selecionar dados cruzados de composições anuais diferentes, como pacientes do BraTS 2018 e do BraTS 2020, simultaneamente no mesmo fluxo de análise visual?**

Confirmamos que a estrutura de dados (as modalidades T1, T1CE, T2 e FLAIR) é idêntica nas versões BraTS 2018 e 2020. Então, expandimos nosso código para conseguir carregar pacientes de ambas as bases de dados de forma organizada. Isso comprovou que nosso processo de análise funciona independentemente da versão do *dataset*, o que nos permite usar uma diversidade clínica muito maior.

- **Quais especificações técnicas e modificações o dataset já continha antes da nossa aplicação da técnica 2.5D e normalização?**

Ao explorar as informações técnicas e os metadados, descobrimos que a própria equipe do BraTS já havia feito um trabalho essencial antes de começarmos: eles removeram o crânio (*skull-stripping*), alinharam as imagens ao mesmo modelo anatômico e padronizaram a resolução para 240 x 240 x 155. Nosso trabalho depende diretamente dessa etapa prévia, pois a usamos como base para criar a máscara do tecido cerebral (volumes > 0) e garantir que todos os canais estiverem perfeitamente alinhados.

- ***O quão viável e eficiente é trabalhar com recortes 2.5D, e que especificações técnicas precisam ser seguidas para implementar isso sem quebrar a continuidade do tecido?***

Avaliamos que usar apenas uma fatia 2D simples faria com que perdêssemos o contexto volumétrico do tumor. Por outro lado, a abordagem 3D pura exigia memória (VRAM) excessiva da placa gráfica. A solução ideal foi a geometria 2.5D. Adaptamos nosso processo para usar preenchimento com zeros (*Zero-Padding*) nas bordas do eixo Z e empilhar três fatias adjacentes (z-1, z, z+1) em um único tensor denso de 12 canais por meio de fatiamento sequencial (*slicing*).

- **A implementação de um Gerador de Lotes (DataGenerator) para entregar esses blocos 2.5D conta como uma nova camada de pré-processamento estrito?**

Esclarecemos a diferença entre estatística e software. O Gerador de Lotes (*DataGenerator*) não é pré-processamento estrito, mas sim Engenharia de Dados Dinâmica (*Data Feeding*). Definimos que as matrizes de normalização devem ser calculadas e salvas offline (antes do treino), enquanto o Gerador atua online (durante o treino) apenas roteando os tensores de 12 canais e embaralhando os índices para evitar problemas de falta de memória (OOM) na GPU.

4. Pré-processamento, Limpeza e Rotulagem (Preprocessing/Cleaning/Labeling)

- **Os dados brutos sofreram processamento antes do uso no modelo?** Sim. O *pipeline* de tratamento para viabilizar o treinamento das Redes Neurais Convolucionais incluiu:
 - **Correção de Viés Magnético (N4 Bias Field Correction):** Uso do algoritmo N4 para homogeneizar o sinal e remover artefatos de radiofrequência nas sequências T1 e T1CE.
 - **Normalização Estatística (Brain-Only Z-Score):** Aplicação de Z-Score restrito aos *voxels* de tecido cerebral, ignorando o fundo para alinhar as distribuições de contraste.
 - **Engenharia de Rótulos (Label Encoding):** Conversão das máscaras para formato *One-Hot* representando as sub-regiões de interesse clínico: Whole Tumor (WT), Tumor Core (TC) e Enhancing Tumor (ET).
- **Como a dimensionalidade foi tratada para a rede neural?** Implementou-se a estratégia 2.5D, onde o *DataLoader* empilha fatias adjacentes (z-1, z, z+1) resultando em tensores de 12 canais, preservando o contexto espacial e volumétrico.

5. Usos (Uses)

- **Para que o dataset está sendo utilizado neste projeto?** Para o treinamento e validação do modelo ACU-Net 2.5D, visando a segmentação autônoma de regiões tumorais (WT, TC, ET) como ferramenta de suporte diagnóstico.

6. Processo de Coleta (Collection Process)

- **Como os dados foram adquiridos e qual a sua variabilidade inerente?** Os exames de RM foram coletados retrospectivamente de consórcios multi-institucionais globais. Tal origem heterogênea introduz uma variabilidade técnica significativa, abrangendo diversos *scanners* (1.5T e 3T) e fabricantes. Uma vez que a intensidade do *voxel* é proporcional a sinais de radiofrequência sem escala absoluta, o rigor no pré-processamento (N4 e Z-Score *Brain-Only*) é

mandatório para que a ACU-Net generalize padrões patológicos além das especificidades de cada equipamento.

Relatório do Projeto: Estruturação dos Resultados

Resultados Parciais

Desempenho Quantitativo (Métricas de Segmentação): A validação da ACU-Net 2.5D fundamenta-se no Coeficiente de Similaridade de Dice (DSC) para medir a sobreposição espacial com o *Ground Truth*, avaliando-se as seguintes sub-regiões:

- **Whole Tumor (WT)**
- **Tumor Core (TC)**
- **Enhancing Tumor (ET)**

O desempenho ainda será avaliado.

Eficiência Computacional (Estratégia 2.5D): O empilhamento de fatias (z-1, z, z+1) em tensores de 12 canais superou abordagens 2D ao preservar o contexto volumétrico sem as limitações de memória (OOM) típicas de redes puramente 3D.

Desempenho Quantitativo (Métricas de Segmentação): A validação da **ACU-Net 3D** foi realizada utilizando o **Coeficiente de Similaridade de Dice (DSC)** para medir a sobreposição entre a predição do modelo e o Ground Truth:

- **Whole Tumor (WT):**
 - BraTS 2018: DSC = **71,5%**
 - BraTS 2020: DSC = **74,0%**
O modelo conseguiu mapear corretamente a extensão total do tumor em ambos os datasets.
- **Tumor Core (TC):**
 - BraTS 2018: DSC = **60,7%**
 - BraTS 2020: DSC = **64,1%**
O núcleo sólido do tumor foi identificado com boa precisão, separando-o do tecido circundante.
- **Enhancing Tumor (ET):**
 - BraTS 2018: DSC = **38,5%**
 - BraTS 2020: DSC = **53,0%**
O modelo detectou as regiões de maior malignidade, embora com maior dificuldade nas áreas pequenas ou mais difusas.

Referencias

[1] B. H. Menze, A. Jakab, S. Bauer, J. Kalpathy-Cramer, K. Farahani, J. Kirby, et al. "The Multimodal Brain Tumor Image Segmentation Benchmark (BRATS)", IEEE Transactions on Medical Imaging 34(10), 1993-2024 (2015) DOI: 10.1109/TMI.2014.2377694

[2] S. Bakas, H. Akbari, A. Sotiras, M. Bilello, M. Rozycki, J.S. Kirby, et al., "Advancing The Cancer Genome Atlas glioma MRI collections with expert segmentation labels and radiomic features", Nature Scientific Data, 4:170117 (2017) DOI: 10.1038/sdata.2017.117

[3] S. Bakas, M. Reyes, A. Jakab, S. Bauer, M. Rempfler, A. Crimi, et al., "Identifying the Best Machine Learning Algorithms for Brain Tumor Segmentation, Progression Assessment, and Overall Survival Prediction in the BRATS Challenge", arXiv preprint arXiv:1811.02629 (2018)

[4] G. Barbagallo et al. "Multimodal Imaging in Parkinson's Disease", International Review of Neurobiology (2016) DOI: 10.1016/bs.irm.2018.08.007; [5] K. Ito et al. "Imaging biomarkers in Parkinson's disease", (2017); [6] S. Zanigni et al. "Structural and functional MRI in Parkinsonism", (2017)

[5] [MICCAI BraTS 2018: Data | Section for Biomedical Image Analysis \(SBIA\) | Perelman School of Medicine at the University of Pennsylvania](#)

[6] Talukder, Alamin, Abu Layek, Aslam Hossain, Aminul Islam, Mohammad Nur-e-Alam, Mohsin Kazi et al. "ACU-Net: Attention-based convolutional U-Net model for segmenting brain tumors in fMRI images."

[7] Produzido por meio de inteligência artificial. Tecnologia de IA Generativa, Google Gemini Pro

[8] [NiBabel: Documentação para acesso e leitura de arquivos NIfTI](#)